



# 最优化方法：救命笔记

献给还没复习的朋友们

作者：Youwei Zhang

组织：天之智慧研究会

时间：May 18, 2022

版本：1.0



我已成仙，法力无边

各人自扫门前雪，休管他人瓦上霜。——我不同意

# 1. 牛顿法

## 算法

给定控制误差  $\varepsilon > 0$ .

Step 1 取初始点  $x_0$ , 令  $k = 0$ .

Step 2 计算  $g_k$ .

Step 3 若  $\|g_k\| \leq \varepsilon$ , 则  $x^* = x_k$ , 停; 否则计算  $G_k$ , 并由  $G_k p_k = -g_k$  解出  $p_k$ .

Step 4 令  $x_{k+1} = x_k + p_k$ ,  $k = k + 1$ , 转 Step 2.



**练习** 试用牛顿 (Newton) 法求下列问题的最优解:

$$\min f(x) = \frac{1}{2}x_1^2 + \frac{3}{2}x_2^2 - x_1x_2 - 2x_2,$$

初始点  $x^{(0)} = (-1, -1)^T$ ;

**解**

$$g(x) = \begin{pmatrix} x_1 - x_2 \\ 3x_2 - x_1 - 2 \end{pmatrix}, G(x) = \begin{pmatrix} 1 & -1 \\ -1 & 3 \end{pmatrix} \text{ 正定}$$

$$x^{(0)} = (-1, -1)^T, g_0 = (0, -4)^T, G_0 = \begin{pmatrix} 1 & -1 \\ -1 & 3 \end{pmatrix}$$

$$\Rightarrow X^{(1)} = X^{(0)} - G^{-1}g_0 = (1, 1)^T,$$

此时,  $g_1 = (0, 0)^T$ , 故  $X^* = X^{(1)} = (1, 1)^T, f^* = -1$ .

**练习** 试用牛顿 (Newton) 法求下列问题的最优解:

$$\min f(X) = x_1^2 + 2x_2^2 - 2x_1x_2 - 4x_1,$$

取初始点  $X^{(0)} = (1, 1)^T$ .

**解**

$$g(x) = \begin{pmatrix} 2x_1 - 2x_2 - 4 \\ 4x_2 - 2x_1 \end{pmatrix}, G(x) = \begin{pmatrix} 2 & -2 \\ -2 & 4 \end{pmatrix} \text{ 正定}$$

$$x^{(0)} = (1, 1)^T, g_0 = (-4, 2)^T, G_0 = \begin{pmatrix} 2 & -2 \\ -2 & 4 \end{pmatrix}$$

$$\Rightarrow X^{(1)} = X^{(0)} - G^{-1}g_0 = (4, 2)^T,$$

此时,  $g_1 = (0, 0)^T$ , 故  $X^* = X^{(1)} = (4, 2)^T, f^* = -8$ .

**笔记** 对于二次型函数, 由于牛顿法的方向直指中心, 且一步到位, 能够一步走到极值点, 所以求  $X^*$  的时候, 直接令  $g(x) = 0$  即可。

## 2. 拟牛顿法

### 算法

给定控制误差  $\varepsilon$ ,

Step 1 给定初始点  $x_0$ , 初始矩阵  $H_0$  (通常取单位阵), 计算  $g_0$ , 令  $k = 0$ .

Step 2 令  $p_k = -H_k g_k$ .

Step 3 由精确一维搜索确定步长  $\alpha_k$ ,

$$f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k).$$

Step 4 令  $x_{k+1} = x_k + \alpha_k p_k$ .

Step 5 若  $\|g_{k+1}\| \leq \varepsilon$ , 则  $x^* = x_{k+1}$  停; 否则令

$$s_k = x_{k+1} - x_k, \quad y_k = g_{k+1} - g_k.$$

Step 6 由 DFP 修正公式  $H_{k+1} = H_k - \frac{H_k y_k y_k^T H_k}{y_k^T H_k y_k} + \frac{s_k s_k^T}{y_k^T s_k}$  得  $H_{k+1}$ . 令  $k = k + 1$ , 转 Step 2.




### 笔记

1. 确定初始点, 行走方向 (求这点的梯度  $g_k$  和  $H_k$ , 方向  $p_k = -H_k g_k$ )
2. 确定步长 ( $\min_{\alpha \geq 0} f(x_k + \alpha p_k)$ )
3. 走到下一点 ( $x_{k+1} = x_k + \alpha_k p_k$ ), 再重复上述操作


**终止条件:** 这一点的梯度  $g_k = 0$  或很小的时候, 就不要往下一个点走了, 这点就为最优点.

**$H_k$  求解时的两个关键向量:** 分别是两点的坐标差和梯度差

### 拟牛顿法步骤示意图



1. 标注初始点的信息: 坐标, 梯度,  $H_0$
2. 三个信息已知, 可立刻求出方向  $p_0$
3. 此时可将  $\alpha_0 p_0$  代入  $f$ , 求出步长, 使得  $f$  在  $p_0$  这个方向的值最小
4. 步长和方向都确定后, 就能让  $x_0$  走到  $x_1$  了



1. 标注  $x_1$  点的信息: 坐标, 梯度,  $H_1$   
其中  $H_1$  由红色信息求出
2. 三个信息已知, 可立刻求出方向  $p_1$
3. 此时可将  $\alpha_1 p_1$  代入  $f$ , 求出步长
4. 步长和方向都确定后, 就能让  $x_1$  走到  $x_2$  了

**练习** 用 DFP(变尺度) 法求解下列无约束最优化问题:

$$\min f(x) = 2x_1^2 + x_2^2 + 2x_1x_2 + x_1 - x_2;$$

取初始点  $x^{(0)} = (0, 0)^T$ ,  $H_0 = E$ ;

解

$$\nabla f(x) = (4x_1 + 2x_2 + 1, 2x_2 + 2x_1 - 1),$$

初始点信息:  $x^{(0)} = (0, 0)^T$ ,  $g_0 = (1, -1)$ ,  $H_0 = \begin{pmatrix} 1 & \\ & 1 \end{pmatrix}$ ,

确定方向:  $p_0 = -H_0 g_0 = (-1, 1)^T$ ,

确定步长:  $\min_{\lambda \geq 0} f(x^{(0)} + \lambda p_0) = \min_{\lambda \geq 0} \lambda^2 - 2\lambda$ ,  $\varphi'(\lambda) = 2\lambda - 2 = 0$ , 得  $\lambda_0 = 1$ ,

走向下一点  $x^{(1)}$ :  $x^{(1)} = x^{(0)} + \lambda p_0 = (-1, 1)^T$ ,

新点  $x^{(1)}$  的信息:  $x^{(1)} = (-1, 1)^T$ ,  $g_1 = (-1, -1)^T$ ,  $H_1 =$  待求

求解  $H_1$ :

$$\begin{aligned} s_0 &= x^{(1)} - x^{(0)} = (-1, 1)^T, y_0 = g_1 - g_0 = (-2, 0)^T, H_1 = H_0 + \frac{s_0 s_0^T}{y_0^T s_0} - \frac{H_0 y_0 y_0^T H_0}{y_0^T H_0 y_0} \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} - \frac{1}{4} \begin{pmatrix} 4 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1/2 & -1/2 \\ -1/2 & 3/2 \end{pmatrix}, \end{aligned}$$

确定  $x^{(1)}$  的行走方向:  $p_1 = -H_1 g_1 = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$ ,

确定步长:  $\min_{\lambda \geq 0} f(x^{(1)} + \lambda p_1) = \min_{\lambda \geq 0} \lambda^2 - \lambda - 1$ , 得  $\lambda_1 = \frac{1}{2}$ ,

走向下一点  $x^{(2)}$ :  $x^{(2)} = x^{(1)} + \lambda p_1 = (-1, \frac{3}{2})^T$ ,

$x^{(2)}$  的信息:  $x^{(2)} = (-1, \frac{3}{2})^T$ ,  $g_2 = (0, 0)^T$ , 梯度为 0, 终止迭代.

所以极小点  $x^{(2)} = (-1, 3/2)$ ,  $f^* = -\frac{5}{4}$ .

练习 试用 DFP(变尺度) 法, 求出  $X^{(1)}$  和变尺度矩阵  $H_1$  以及搜索方向  $p_1$ ,

$$\min f(X) = x_1^2 + 2x_2^2 - 2x_1x_2 - 4x_1,$$

取初始点  $X^{(0)} = (1, 1)^T$ ,  $H_0 = E$ .

解 过程如上, 太麻烦了, 自己写.

### 3. 共轭梯度法

#### 算法

给定控制误差  $\varepsilon$ .

Step 1 给定初始点  $x_1, k = 1$ .

Step 2 计算  $g_k = g(x_k)$ .

Step 3 若  $\|g_k\| \leq \varepsilon$ , 则  $x^* = x_k$  停; 否则令

$$p_k = -g_k + \beta_{k-1}p_{k-1},$$
$$\beta_{k-1} = \begin{cases} \frac{g_k^T g_k}{g_{k-1}^T g_{k-1}}, & \text{当 } k > 1 \text{ 时,} \\ 0, & \text{当 } k = 1 \text{ 时.} \end{cases}$$

Step 4 由精确一维搜索确定步长  $\alpha_k$ , 满足

$$f(x_k + \alpha_k p_k) = \min_{\alpha \geq 0} f(x_k + \alpha p_k).$$

Step 5 令  $x_{k+1} = x_k + \alpha_k p_k, k = k + 1$ , 转 Step 2.




#### 笔记


下面 3 句话不清楚什么意思不用管, 直接看图即可.

1. 共轭梯度法核心是求一组共轭向量, 也是  $G$  的特征向量, 组成过渡矩阵  $P$ ; 在坐标变换  $x = Py$  下就是正交向量了, 二次型的变量也解耦了. 看二次型的等高线 (椭圆) 有, 沿着共轭方向走, 其实就是沿着变换后坐标系下的坐标轴方向走, 由于变换后二次函数变量之间互不耦合, 所以一维搜索下分别取极值后, 就是最终的极值.
2. 共轭向量可以由已知点的梯度用类似"施密特共轭化"的方法求得, 对于二次型函数, 这个公式还可以简化
3. 共轭梯度法也可以用来解实对称矩阵特征值, 也就是解方程, 参数量巨大也无所谓


#### 共轭梯度法步骤示意图



1. 标注初始点的信息: 坐标, 梯度
2. 初始方向  $p_0$  取负梯度方向  $-g_0$
3. 此时可将  $\alpha_0 p_0$  代入  $f$ , 求出步长, 使得  $f$  在  $p_0$  这个方向的值最小
4. 步长和方向都确定后, 就能让  $x_0$  走到  $x_1$  了



1. 标注  $x_1$  点的信息: 坐标, 梯度
2. 红色信息已知, 可立刻求出方向  $p_1$   
 $p_1 = -g_1 + \beta_0 p_0$   
 $\beta_0 = \frac{\|g_1\|^2}{\|g_0\|^2}$  (仅适用于二次型)
3. 此时可将  $\alpha_1 p_1$  代入  $f$ , 求出步长
4. 步长和方向都确定后, 就能让  $x_1$  走到  $x_2$  了

 **练习** 试用共轭梯度 (FR) 法求下列问题的最优解:

$$\min f(x) = x_1^2 + 4x_2^2,$$

取初始点为  $x^{(0)} = (4, 1)^T$ ;

**解**

$$\nabla f(x) = g(x) = (2x_1, 8x_2)^T$$

**初始点信息:**  $x^{(0)} = (4, 1)^T, g_0 = (8, 8)^T$ .

**确定方向  $p_0$ :**  $p_0 = -g_0 = (-8, -8)^T$ .

**确定步长  $\alpha_0$ :**  $f(x^{(0)} + \alpha_0 p_0) = (4 - 8\alpha_0)^2 + 4(1 - 8\alpha_0)^2$ , 令  $f'(\alpha_0) = 0$ , 得  $\alpha_0 = \frac{1}{5}$ .

**走向下一点  $x^{(1)}$ :**  $x^{(1)} = x^{(0)} + \alpha_0 p_0 = (\frac{12}{5}, -\frac{3}{5})^T$ .


**新点  $x^{(1)}$  的信息:**  $x^{(1)} = (\frac{12}{5}, -\frac{3}{5})^T, g_1 = (\frac{24}{5}, -\frac{24}{5})^T$

**确定方向  $p_1$ :**  $p_1 = -g_1 + \beta_0 p_0 = -g_1 + \frac{\|g_1\|^2}{\|g_0\|^2} p_0 = \frac{48}{5}(-4, 1)^T$ , 因为就是一个方向, 所以取  $p_1 = (-4, 1)^T$ .

**确定步长  $\alpha_1$ :**  $f(x^{(1)} + \alpha_1 p_1) = (2.4 - 4\alpha_1)^2 + 4(-0.6 + \alpha_1)^2$ , 令  $f'(\alpha_1) = 0$ , 得  $\alpha_1 = 0.6$ .

**走向下一点  $x^{(2)}$ :**  $x^{(2)} = x^{(1)} + \alpha_1 p_1 = (0, 0)^T$ , 顺便求出梯度:  $g_2 = (0, 0)^T$

所以,  $X^* = (0, 0), \min f(X^*) = 0$ .

 **练习** 试用共轭梯度 (FR) 法求下列问题的最优解:

$$\min f(X) = 2x_1^2 + x_2^2 + 2x_1x_2 + x_1 - x_2,$$

取初始点为  $X^{(0)} = (0, 0)^T$ .

**解** 步骤同上.

## 4.KT 条件

### 定理

对于一般约束最优化问题:

$$\begin{aligned} \min f(\mathbf{x}), \mathbf{x} \in \mathbf{R}^n, \\ \text{s.t. } c_i(\mathbf{x}) &= 0, \quad i \in E = \{1, \dots, l\}, \\ c_i(\mathbf{x}) &\geq 0, \quad i \in I = \{l+1, \dots, m\} \end{aligned}$$

若

(i)  $x^*$  为局部最优解, 其有效集  $I^* = \{i \mid c_i(x^*) = 0, i \in I\}$ ;

(ii)  $f(\mathbf{x}), c_i(\mathbf{x}) (i = 1, \dots, m)$  在点  $\mathbf{x}^*$  可微;

(iii) 对所有  $i \in E \cup I^*, \nabla c_i(x^*)$  线性无关.

则存在向量  $\lambda^* = (\lambda_1^*, \dots, \lambda_m^*)^T$  使得

$$\begin{aligned} \nabla f(x^*) - \sum_{i=1}^m \lambda_i^* \nabla c_i(x^*) &= 0, \\ \lambda_i^* c_i(x^*) &= 0, \lambda_i^* \geq 0, \quad i \in I, \\ c_i(x^*) &= 0, \quad i \in E. \end{aligned}$$



**练习** 求解下列约束问题:

$$\begin{aligned} \min f(x) &= (x_1 - x_2 + x_3)^2 \\ \text{s.t. } \begin{cases} c_1(x) = x_1 + 2x_2 - x_3 = 5 \\ c_2(x) = x_1 - x_2 - x_3 = -1 \end{cases} \end{aligned}$$

(1) 写出 K-T 条件;

(2) 求出 K-T 点, 最优解和最优值.

解 ...

**练习** 求解下列约束最优化问题:

$$\begin{aligned} \min f(X) &= x_1^2 + x_2^2 + x_3^2 \\ \text{s.t. } \begin{cases} c_1(X) = x_1 + 2x_2 - x_3 - 4 = 0, \\ c_2(X) = x_1 - x_2 - x_3 + 2 = 0; \end{cases} \end{aligned}$$

(1) 写出 K-T 条件;

(2) 求出 K-T 点, 最优解和最优值.

解 ...

## 5. 罚函数法

### 算法

#### 外罚函数法

对于约束问题:

$$\begin{aligned} \min & f(\mathbf{x}), \mathbf{x} \in \mathbf{R}^n, \\ \text{s.t.} & c_i(\mathbf{x}) = 0, \quad i \in E = \{1, 2, \dots, l\} \\ & c_i(\mathbf{x}) \geq 0, \quad i \in I = \{l+1, \dots, m\} \end{aligned}$$

取控制误差  $\varepsilon > 0$  和罚因子的放大系数  $c > 1$  (可取  $\varepsilon = 10^{-4}, c = 10$ ).

Step 1 给定初始点  $x_0$  (可以不是可行点) 和初始罚因子  $\sigma_1$  (可取  $\sigma_1 = 1$ ), 令  $k = 1$ .

Step 2 以  $x_{k-1}$  为初始点求无约束问题:

$$\min P(x, \sigma_k) = f(x) + \sigma_k \tilde{P}(x),$$

其中

$$\tilde{P}(\mathbf{x}) = \sum_{i=1}^l |c_i(\mathbf{x})|^\beta + \sum_{j=l+1}^m |\min(0, c_j(\mathbf{x}))|^\alpha, \quad \alpha \geq 1, \beta \geq 1,$$

得最优解  $\mathbf{x}_k = \mathbf{x}(\sigma_k)$ .

Step 3 若  $\sigma_k \tilde{P}(\mathbf{x}_k) < \varepsilon$ , 则以  $\mathbf{x}_k$  为近似最优解, 停止. 否则令  $\sigma_{k+1} = c\sigma_k, k = k+1$ , 转 Step 2.



### 笔记

1. 这种方法就是给目标函数  $f(x)$  加一个惩罚项  $\tilde{P}(x)$ , 变成增广目标函数  $P(x)$ . 使原目标函数在可行域内不受惩罚, 在违反约束的地方受到惩罚 (理想情况为  $\infty$ ), 其几何解释之前在群聊天里发过, 不记得可以翻记录, 那里讲的非常清楚.
2. 直接求  $P(x)$  的无约束极值即可.

### 练习 求解约束问题

$$\begin{aligned} \min & f(x) = x_1^2 + x_2^2 \\ \text{s.t.} & x_1 + 1 \leq 0 \end{aligned}$$

解令

$$P(x, \sigma) = \begin{cases} x_1^2 + x_2^2, & x_1 + 1 \leq 0 \\ x_1^2 + x_2^2 + \sigma(x_1 + 1)^2, & x_1 + 1 > 0 \end{cases}$$

$$\text{令} \begin{cases} \frac{\partial P}{\partial x_1} = 0 \\ \frac{\partial P}{\partial x_2} = 0 \end{cases}$$

$$\text{当 } x_1 \leq -1 \text{ 时, } \begin{cases} \frac{\partial P}{\partial x_1} = 2x_1, \\ \frac{\partial P}{\partial x_2} = 2x_2, \end{cases} \text{ 解得 } (x_1, x_2) = (0, 0), \text{ 舍去;}$$

$$\text{当 } x_1 > -1 \text{ 时, } \begin{cases} \frac{\partial P}{\partial x_1} = 2x_1 + 2\sigma(x_1 + 1) \\ \frac{\partial P}{\partial x_2} = 2x_2, \end{cases} \text{ 解得 } (x_1, x_2) = \left(-\frac{\sigma}{\sigma+1}, 0\right),$$

它是  $P(x, \sigma)$  的最优点, 最优值为  $P(x, \sigma) = \frac{\sigma}{\sigma+1}$ .

当  $\sigma \rightarrow +\infty$  时,  $x_1(\sigma) \rightarrow -1, x_2(\sigma) \rightarrow 0$ . 因此  $x(\sigma) \rightarrow x^*, P(x, \sigma) \rightarrow f(x^*) = 1$ .

注 一般题目约束是起作用的, 所以不必求没有惩罚的那一段函数的极值.



## 练习 求解约束问题

$$\begin{aligned}\min f(x) &= x_1^2 + x_2^2 \\ \text{s.t. } x_1 + 1 &= 0\end{aligned}$$

解 令

$$P(x, \sigma) = \begin{cases} x_1^2 + x_2^2, & x_1 + 1 = 0, \\ x_1^2 + x_2^2 + \sigma(x_1 + 1)^2, & x_1 + 1 \neq 0, \end{cases} = x_1^2 + x_2^2 + \sigma(x_1 + 1)^2$$

$$\text{令 } \begin{cases} \frac{\partial P}{\partial x_1} = 0 \\ \frac{\partial P}{\partial x_2} = 0 \end{cases}, \begin{cases} \frac{\partial P}{\partial x_1} = 2x_1 + 2\sigma(x_1 + 1) \\ \frac{\partial P}{\partial x_2} = 2x_2, \end{cases}, \text{解得 } (x_1, x_2) = (-\frac{\sigma}{\sigma+1}, 0),$$

它是  $P(x, \sigma)$  的最优点, 最优值为  $P(x, \sigma) = \frac{\sigma}{\sigma+1}$ .

当  $\sigma \rightarrow +\infty$  时,  $x_1(\sigma) \rightarrow -1, x_2(\sigma) \rightarrow 0$ . 因此  $x(\sigma) \rightarrow x^*, P(x, \sigma) \rightarrow f(x^*) = 1$ .

## 练习 求解约束问题:

$$\begin{aligned}\min f(x) &= x_1^2 + x_1x_2 + x_2^2, \\ \text{s.t. } c(x) &= x_1 + x_2 - 2 = 0\end{aligned}$$

解 这道题就是后面的乘子法的试题, 这里先用外罚函数法写一写, 后面的乘子法求解步骤类似. 考试的话只考其一, 最近两次考的都是乘子法.

## 笔记

### 计算机求解思路

构造一堆增广函数, 惩罚项系数按一定的倍数增加, 分别用无约束算法求解每个增广函数的极值点

以上上题为例, 大致步骤如下 (惩罚系数  $\sigma$  的增大倍数设为 10):


1. 给定初始点  $x_0$ , 增广目标函数  $P(x, \sigma_1) = P(x, 0.1) = x_1^2 + x_2^2 + 0.1(x_1 + 1)^2$ , 用牛顿法或者别的无约束算法求得  $P(x, \sigma_1)$  的最优点, 记为  $x_1$ .

2. 将  $x_1$  视为新的初始点, 增广目标函数  $P(x, \sigma_2) = P(x, 1) = x_1^2 + x_2^2 + (x_1 + 1)^2$ , 用牛顿法或者别的无约束算法求得  $P(x, \sigma_2)$  的最优点, 记为  $x_2$ .

3. 将  $x_2$  视为新的初始点, 增广目标函数  $P(x, \sigma_3) = P(x, 10) = x_1^2 + x_2^2 + 10(x_1 + 1)^2$ , 用牛顿法或者别的无约束算法求得  $P(x, \sigma_3)$  的最优点, 记为  $x_3$ .

终止条件:  $\sigma_k \tilde{P}(x_k) < \varepsilon$  因为 KT 条件没法直接拿来用, 这里是因为  $\{x_k\}$  收敛时,  $\sigma_k \tilde{P}(x_k) \rightarrow 0$

### 罚函数法步骤示意图



算法步骤: 将  $x_0$  丢进  $P(x, \sigma_1)$  中做无约束优化, 得到  $x_1$ ;  
再把  $x_1$  丢进  $P(x, \sigma_2)$  中优化, 得到  $x_2$ ; 以此类推.

## 内罚函数法

求解约束问题

$$\begin{aligned} \min f(x), \quad x \in \mathbf{R}^n \\ \text{s.t.} \quad c_i(x) \geq 0, \quad i = 1, \dots, m \end{aligned}$$

且其可行域的内点集  $D_0 \neq \emptyset$ .

构造如下的增广目标函数:

$$B(x, r) = f(x) + r\tilde{B}(x),$$

其中令

$$\tilde{B}(x) = \sum_{i=1}^m \frac{1}{c_i(x)} \text{ 或 } \tilde{B}(x) = -\sum_{i=1}^m \ln(c_i(x)),$$

取控制误差  $\varepsilon > 0$  和罚因子的缩小系数  $0 < c < 1$  (可取  $\varepsilon = 10^{-4}$ ,  $c = 0.1$ ).

Step 1 选定初始点  $x_0 \in D_0$ , 给定  $r_1 > 0$  (取  $r_1 = 10$ ), 令  $k = 1$ .

Step 2 以  $x_{k-1}$  为初始点, 求解无约束问题

$$\min B(x, r_k) = f(x) + r_k\tilde{B}(x),$$

得最优解  $x_k = x(r_k)$ .

Step 3 若  $r_k\tilde{B}(x_k) < \varepsilon$ , 则  $x_k$  为近似最优解, 停. 否则, 令  $r_{k+1} = cr_k$ ,  $k = k + 1$  转 Step 2.



 **练习** (非数学专业必答) 请用内点法求解下列问题:

$$\begin{aligned} \min f(X) &= \frac{1}{6}(x_1 + 1)^3 + x_2 - 1 \\ \text{s.t.} \quad &\begin{cases} c_1(X) = x_1 - 1 \geq 0 \\ c_2(X) = x_2 - 1 \geq 0 \end{cases} \end{aligned}$$

(1) 推导其最优解;

(2) 若取  $X_0 = (3, 5)$ ,  $r_1 = 2$ , 公比  $c = \frac{1}{2}$  时, 指出用何种方法可计算点列  $X_1, X_2, \dots, X_k, \dots$ ;

解 ...

## 6. 乘子法

### 算法

#### 等式约束问题的乘子法 (PH 算法)

Step 1 选定初始点  $x_0$ , 初始乘子向量  $\lambda_1$ , 初始罚因子  $\sigma_1$  及其放大系数  $c > 1$ , 控制误差  $\varepsilon > 0$  与常数  $\theta \in (0, 1)$ , 令  $k = 1$ .

Step 2 以  $x_{k-1}$  为初始点求解无约束问题

$$\min M(\mathbf{x}, \lambda_k, \sigma_k) = f(\mathbf{x}) - \lambda_k^T \mathbf{c}(\mathbf{x}) + \frac{\sigma_k}{2} \mathbf{c}(\mathbf{x})^T \mathbf{c}(\mathbf{x})$$

得最优解  $\mathbf{x}_k$ .

Step 3 当  $\|\mathbf{c}(\mathbf{x}_k)\| < \varepsilon$  时,  $\mathbf{x}_k$  为所求最优解, 停. 否则转 Step 4.

Step 4 当  $\|\mathbf{c}(\mathbf{x}_k)\| / \|\mathbf{c}(\mathbf{x}_{k-1})\| \leq \theta$  时, 转 Step 5, 否则令  $\sigma_{k+1} = c\sigma_k$ , 转 Step 5.

Step 5 令  $\lambda_{k+1} = \lambda_k - \sigma_k \mathbf{c}(\mathbf{x}_k)$ ,  $k = k + 1$ , 转 Step 2.



### 笔记

#### 算法设计思路 (不清楚在讲啥可跳过)

原始形式的外罚函数法存在一个严重的缺点, 就是  $\sigma$  必须趋于无穷大, 才能让点列收敛到最优点, 但是这样的增广函数性质很垃圾, 梯度差的一比, 很难优化。而拉格朗日函数虽然可以直接使用无约束优化算法, 但是有的情况下这个拉格朗日函数不存在极值点, 其稳定点是个鞍点, 无约束算法不一定能走到这个鞍点上来。

解决方案: 对拉格朗日函数再进行约束, 使它变成约束问题, 并且这个约束问题与原始约束问题等价。对这个拉格朗日函数进行外罚函数法。

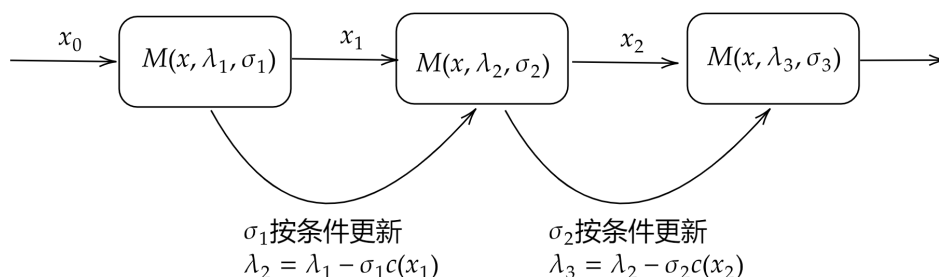
由于带约束的拉格朗日函数, 在最优点处, 其 Hessian 矩阵一定在约束可行域内正定, 由 Finsler 定理 (教材 P158) 可以证明, 一定存在一个数  $\sigma^* > 0$ , 使得当  $\sigma \geq \sigma^*$  时, 对于整个空间, 都有  $\nabla_x^2 L(x^*, \lambda^*) + \sigma \nabla \mathbf{A}(x^*) \mathbf{A}(x^*)^T$  正定, 其中  $\nabla \mathbf{A}(x^*) \mathbf{A}(x^*)^T$  是罚函数  $\tilde{P}(x) = \frac{1}{2} \mathbf{c}(x)^T \mathbf{c}(x)$  的二阶导。

而  $\nabla_x^2 L(x^*, \lambda^*) + \sigma \nabla \mathbf{A}(x^*) \mathbf{A}(x^*)^T$  是如下函数 (增广拉格朗日函数) 的 Hessian 矩阵:

$$M(x, \lambda, \sigma) = L(x, \lambda) + \frac{\sigma}{2} \mathbf{c}(x)^T \mathbf{c}(x)$$

说明了上述条件下, 在最优点处, 拉格朗日增广函数在全空间内都是正定的, 就能用无约束优化算法, 并且梯度性质较好。

## 乘子法步骤示意图



$\sigma_1$ 按条件更新: 当  $\frac{\|c(x_2)\|}{\|c(x_1)\|} > \theta$  时, 更新  $\sigma_2 = c\sigma_1$ ; 否则不更新  $\sigma_1$

算法步骤: 将  $x_0$  丢进  $M(x, \lambda_1, \sigma_1)$  中做无约束优化, 得到  $x_1$ ;  
 再把  $x_1$  丢进  $M(x, \lambda_2, \sigma_2)$  中优化, 得到  $x_2$ ; 以此类推。

终止条件:  $\|c(x_2)\| < \epsilon$

手算步骤: 直接令  $\nabla_x M(x, \lambda, \sigma) = 0$ , 解出  $x^*, \lambda^*, \sigma^*$  即可

**练习** 试用乘子法求下列问题的最优解:

$$\begin{aligned} \min f(x) &= x_1^2 + x_1 x_2 + x_2^2, \\ \text{s.t. } c(x) &= x_1 + x_2 - 2 = 0 \end{aligned}$$

**解**

增广 Lagrange 函数为:

$$M(\mathbf{x}, \lambda, \sigma) = \frac{1}{2} \mathbf{x}^T \mathbf{G} \mathbf{x} - \lambda (x_1 + x_2 - 2) + \frac{\sigma}{2} (x_1 + x_2 - 2)^2, \sigma > 0,$$

令

$$\nabla M(\mathbf{x}, \lambda, \sigma) = \mathbf{G} \mathbf{x} - \lambda \nabla c(\mathbf{x}) + \sigma c(\mathbf{x}) \nabla c(\mathbf{x}) = 0$$

其中

$$\nabla c(\mathbf{x}) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \lambda \nabla c(\mathbf{x}) = \lambda \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \sigma \nabla c(\mathbf{x}) \cdot c(\mathbf{x}) = \sigma \begin{pmatrix} 1 \\ 1 \end{pmatrix} (1, 1) \mathbf{x} - 2\sigma \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \sigma \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \mathbf{x} - 2\sigma \begin{pmatrix} 1 \\ 1 \end{pmatrix},$$

所以,


$$\nabla M(\mathbf{x}, \lambda, \sigma) = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \mathbf{x} - \lambda \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \sigma \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \mathbf{x} - 2\sigma \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 2+\sigma & 1+\sigma \\ 1+\sigma & 2+\sigma \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} - \begin{pmatrix} \lambda+2\sigma \\ \lambda+2\sigma \end{pmatrix} = 0,$$

解得,

$$x_1 = x_2 = \frac{\lambda + 2\sigma}{3 + 2\sigma} \rightarrow 1 (\sigma \rightarrow \infty),$$

故存在  $\sigma^*$ , 使得  $\frac{\lambda + 2\sigma^*}{3 + 2\sigma^*} = 1$ , 得  $\lambda = 3$ . 因此

$$\mathbf{x}^* = (1, 1)^T, f^* = 3.$$

 **练习** 请用乘子法求下列问题的最优解:

$$\begin{aligned} \min f(x) &= x_1^2 - 3x_2 - x_2^2, \\ \text{s.t. } x_2 &= 0. \end{aligned}$$

**解**


增广 Lagrange 函数为:

$$M(x, \lambda, \sigma) = x_1^2 - (\lambda + 3)x_2 + \frac{\sigma - 2}{2}x_2^2$$

令

$$\begin{aligned} \frac{\partial M}{\partial x_1} &= 2x_1 = 0, \\ \frac{\partial M}{\partial x_2} &= (\sigma - 2)x_2 - (\lambda + 3) = 0, \end{aligned}$$

得  $x_0 = \left(0, \frac{\lambda+3}{\sigma-2}\right)^T$ . 要求  $x_0$  满足的约束条件  $x_2 = 0$ , 必须取  $\lambda = -3$ , 从而  $x_0 = (0, 0)^T = x^*$ , 即为原约束问题的最优解.

 **练习** (数学专业必答) 对上题, 已知初始点  $X_0$ , 初始乘子向量  $\lambda_1$ , 初始罚因子  $\sigma_1$ , 放大系数  $c > 1$ , 控制误差  $\varepsilon > 0$ , 常数  $\theta \in (0, 1)$ , 如何求出迭代点列  $X_1, X_2, \dots, X_k, \dots$ ;

**解**

就是简要概述一下算法, 结合上面给的算法步骤和图片, 随便讲讲, 注意  $\sigma$  和  $\lambda$  的更新, 以及终止条件。

## 7. 简约梯度法

### 算法

需要用到的公式：

$$1. \quad r(x^N) = \nabla_N f(x^B(x^N), x^N) - (B^{-1}N)^T \nabla_B f(x^B(x^N), x^N)$$

$$2. \quad (p_k^N)_j = \begin{cases} -(x_k^N)_j r_j(x_k^N), & \text{当 } r_j(x_k^N) > 0 \text{ 时,} \\ -r_j(x_k^N), & \text{当 } r_j(x_k^N) \leq 0 \text{ 时.} \end{cases}$$

$$3. \quad p_k^B = -B^{-1}Np_k^N$$

$$4. \quad \alpha_{\max} = \begin{cases} \min \left\{ \frac{(x_k)_j}{-(p_k)_j} \mid (p_k)_j < 0 \right\}, & \text{当 } p_k \neq 0 \text{ 时,} \\ +\infty, & \text{当 } p_k \geq 0 \text{ 时,} \end{cases}$$

Step 1 给定初始基可行解  $x_1 = \begin{pmatrix} x_1^B \\ x_1^N \end{pmatrix} \geq 0$ , 其中  $x_1^B$  为基向量, 令  $k = 1$ .

Step 2 对应于  $x_k = \begin{pmatrix} x_k^B \\ x_k^N \end{pmatrix}$  将  $A$  分解成  $A = (B, N)$ . 由公式 1, 2 和 3 分别计算  $r(x_k^N)$ ,  $p_k^N$  和  $p_k^B$ , 令

$$p_k = \begin{pmatrix} p_k^B \\ p_k^N \end{pmatrix}.$$


Step 3 若  $p_k = 0$ , 则  $x_k$  为 KT 点, 停; 否则, 由式 4 计算  $\alpha_{\max}$ , 求  $\alpha_k$  使

$$f(x_k + \alpha_k p_k) = \min_{0 \leq \alpha \leq \alpha_{\max}} f(x_k + \alpha p_k),$$


令  $x_{k+1} = x_k + \alpha_k p_k$ , 转 Step 4.

Step 4 若  $x_{k+1}^B > 0$ , 则基向量不变, 令  $k = k + 1$ , 转 Step 2; 若有某个  $j$  使  $(x_{k+1}^B)_j = 0$ , 则将  $(x_{k+1}^B)_j$  换出基, 而以  $x_{k+1}^N$  中具有最大分量的变量换入基, 构成新的基向量  $x_{k+1}^B$  与非基向量  $x_{k+1}^N$ , 令  $k = k + 1$ , 转 Step 2.



 **练习** 试述简约梯度法的迭代步骤;

解 ...

 **练习** 试用简约梯度法求出初始点  $X^{(1)}$  和搜索方向  $p_1$ , 以及步长的上限  $\alpha_{\max}$ ;

$$\begin{aligned} \min f(X) &= x_1^2 + x_1 x_2 + 2x_2^2 - 6x_1 - 14x_2, \\ \text{s.t.} \quad &\begin{cases} c_1(X) = x_1 + x_2 + x_3 = 2, \\ c_2(X) = -x_1 + 2x_2 + x_4 = 3, \\ x_i > 0, i = 1, 2, 3, 4; \end{cases} \end{aligned}$$

解 ...